

รายงานการศึกษาแนวทาง AI Agent และ Reinforcement Learning

ฉบับร่างสำหรับถกกับทีมโครงการ · 7 สิงหาคม 2569

สารบัญ

0. บทสรุปสำหรับผู้บริหาร

ข้อสรุปที่สำคัญที่สุดห้าข้อ

1. AI ตัดสินอะไรได้

- 1.1 สามขั้นของการตรวจ
- 1.2 ทำไมขั้นกฎเป็นตัวประกันของโครงการ
- 1.3 ข้อบังคับสี่ข้อของขั้น LLM
- 1.4 ความเสี่ยงทางเทคนิคสองข้อที่ต้อง spike ก่อนล็อกสถาปัตยกรรม

2. จะรู้ได้อย่างไรว่าระบบดีพอ

- 2.1 กฎข้อเดียวที่ละเมิดไม่ได้
- 2.2 การแบ่งข้อมูลสามชุด
- 2.3 ตัววัดที่ใช้ และตัวที่ไม่ใช้
- 2.4 ตาราง “มี N เท่านี้ อ้างอะไรได้”
- 2.5 เพดานมนุษย์ — ตัวหารของทั้งวิทยานิพนธ์
วรรณกรรมบอกอะไร
แปลว่าอะไรกับโครงการนี้
เกณฑ์ความสำเร็จที่ประกาศล่วงหน้า
- 2.6 หัววิธีที่ทำให้ N น้อยมีพลังมากขึ้น
- 2.7 เมื่อ rubric เปลี่ยนเวอร์ชัน
- 2.8 ลำดับการใช้เวลาตรวจของอาจารย์

3. การได้มาซึ่งข้อมูล — และเหตุผลที่หนักที่สุดที่แข่งที่สุดคือวันเปิดภาค

- 3.1 วิชาที่เปิดสอนทุกภาค ซึ่งเปลี่ยนแปลงทั้งหมด
- 3.2 ผลที่ตามมา: หมดที่แข็งแกร่งที่สุดของโครงการคือวันเปิดภาค 1/2569
- 3.3 ข้อมูลที่จะได้จริง
- 3.4 การซ่อมใหญ่ปลายภาค 1
- 4. RL — สิ่งที่โจทย์เรียกว่า RL คืออะไรได้จริง
 - 4.1 พูดตรง ๆ ก่อน: สิ่งที่คุณเรียกว่า RL ส่วนใหญ่ในบริบทนี้ไม่ใช่ RL
 - 4.2 คำถามวิจัย — หนึ่งประโยค
 - 4.3 ทำไมกรอบนี้ล้มไม่ได้โดยโครงสร้าง
 - 4.4 สมมติฐานที่ประกาศล่วงหน้า
 - 4.5 วิธีสร้างเส้นโค้งการเรียนรู้
 - 4.6 การสร้างคู่ preference — จุดที่ทำให้ผิดกันบ่อยที่สุด
 - 4.7 นิยาม state / action / reward ของสาย B
 - 4.8 Reward hacking สี่แบบและวิธีตรวจจับ
 - 4.9 ทรัพยากรและเวลาเครื่อง
 - 4.10 การเชื่อมกับระบบจริง
- 5. ปฏิทินและจุดตัดสินใจหยุด
 - กฎเหล็กสองข้อ
- 6. ย่อหน้าทางถอย — เขียนไว้ให้ใช้ได้ทันที
- 7. สิ่งที่ไม่ห้ามเขียนในเล่ม

0. บทสรุปสำหรับผู้บริหาร

เอกสารนี้ตอบสามคำถาม

- 1. AI ตัดสินอะไรได้ ตัดสินอะไรไม่ได้ และควรจัดสถาปัตยกรรมอย่างไรให้ส่วนที่ตัดสินไม่ได้ไม่ทำให้ทั้งระบบพัง
- 2. จะรู้ได้อย่างไรว่าระบบดีพอ — ตัววัด ขนาดตัวอย่างที่ต้องมี และตัวหารที่ทำให้ตัวเลขมีความหมาย
- 3. RL ในโครงการนี้คืออะไรได้จริงบ้าง — และจะออกแบบการทดลองอย่างไรให้ล้มไม่ได้โดยโครงสร้าง

ข้อสรุปที่สำคัญที่สุดห้าข้อ

#	ข้อสรุป	ผลต่อการออกแบบ
1	เพดานของ AI $\approx$ ระดับที่มนุษย์สองคนตรงกัน งานออกแบบแบบ open-ended มี exact agreement ระหว่างมนุษย์เพียง 55–75%	ต้องวัดเพดานมนุษย์ก่อนวัด AI · ตัวเลขนี้คือตัวหารของทั้งวิทยานิพนธ์
2	ที่ N หลักสิบ QWK อ้างไม่ได้เลย (CI กว้าง ± 0.25)	ต้องประกาศล่วงหน้าว่า N เท่าไรอ้างอิงอะไรได้ ไม่ใช่รายงานตัวเลขที่ได้แล้วค่อยตีความ
3	anchor example ให้ผลตอบแทนต่อหน่วยแรงสูงที่สุด สูงกว่าการฝึกโมเดลมาก	หุ้มแรงไปที่ anchor + การชดเชย bias รายเกณฑ์ ไม่ใช่ที่การเทรน
4	สิ่งที่โจทย์เรียกว่า RL ส่วนใหญ่ไม่ใช่ RL ตามนิยาม	ต้องเขียนในเล่มให้ตรง มิฉะนั้นเป็นจุดที่กรรมการจับได้ง่ายที่สุด
5	ข้อมูลของรายวิชาเดียวห่างจากที่ preference learning ต้องการสองอันดับของขนาด	ตั้งคำถามวิจัยเป็นเส้นโค้งการเรียนรู้ ซึ่งเป็นการทดลองไม่ว่าจะชันหรือแบน

1. AI ตัดสินอะไรได้

1.1 สามชั้นของการตรวจ

ชั้นที่ 1	ตัวอ่านไฟล์	Figma API / PDF → โครงสร้าง + ภาพ
ชั้นที่ 2	ชั้นกฎ	โค้ดล้วน · LLM ห้ามแตะ
ชั้นที่ 3	ชั้น LLM	vision-language model · ดีความ

ชั้นกฎไม่ได้มีไว้แค่ให้คะแนน มันยังป้อน metrics ให้ชั้น LLM ใช้เป็นหลักฐาน เช่น ชั้นกฎบอกว่า “พบขนาดฟอนต์ 11 ขนาดใน 6 หน้าจอ” แล้วชั้น LLM ใช้ข้อเท็จจริงนั้นประกอบการตัดสินเรื่องความสม่ำเสมอ แทนที่จะต้องนับเอง (ซึ่งทำได้ไม่แม่นยำ)

ชั้น	เกณฑ์ที่รับผิดชอบ	ตัวอย่าง
ชั้นกฎ	kind = rule	อัตราส่วน contrast · จำนวนขนาดฟอนต์ · ความสม่ำเสมอของ spacing · สัดส่วนการใช้ component/style · ความครบของสิ่งที่สั่งให้ส่ง
ชั้น LLM	kind = llm	ลำดับชั้นการมองเห็น · โครงสร้างข้อมูลและการนำทาง · ความเหมาะสมของ flow กับโจทย์ผู้ใช้ · คุณภาพ micro-copy
ไม่มีใครทำ	kind = human_only	ความคิดสร้างสรรค์ · ความเหมาะสมเชิงวัฒนธรรม · การตอบโจทย์ที่ต้องรู้บริบทของผู้เรียนคนนั้น

1.2 ทำไมชั้นกฎเป็นตัวประกันของโครงการ

ชั้นกฎไม่ฟังความแม่นยำของ LLM เลย ถ้าชั้น LLM ให้คะแนนได้ไม่ดีพอที่จะใช้จริง ส่วนที่เหลือของระบบ — ชั้นกฎ สมุดคะแนน CLO attainment การสืบย้อน การส่งออก — ยังเป็นระบบที่ใช้งานได้จริงและมีคุณค่าต่อรายวิชา

นี่คือเหตุผลเชิงโครงสร้างที่ทำให้โครงการนี้ไม่มีทางไม่มีผลงานส่ง และทีมควรรู้ตั้งแต่วันแรก เพราะมันเปลี่ยนวิธีจัดลำดับงาน

1.3 ข้อบังคับสี่ข้อของชั้น LLM

- 1. หนึ่ง call ต่อหนึ่งหัวข้อประเมิน ไม่ใช่ call เดียวแล้วให้คืนคะแนนทุกข้อ **เหตุผล:** ให้แต่ละการตัดสินใจอิสระจากกัน · แยกได้ว่าข้อไหนพัง · ตรวจใหม่เฉพาะข้อที่แก้ rubric ได้ **ราคาที่จ่าย:** จำนวน call เพิ่มเป็นเท่าของจำนวนเกณฑ์ — ยอมรับได้ที่ปริมาณงานระดับนี้
- 2. บังคับคืนสามอย่างเสมอ: ระดับ + เหตุผล + หลักฐานที่ชี้ตำแหน่งได้ คำตัดสินที่ชี้หลักฐานไม่ได้ถือว่าไม่สมบูรณ์
- 3. ห้ามเก็บค่าความมั่นใจที่โมเดลรายงานเอง — ค่าที่ LLM บอกว่ามั่นใจ 90% ไม่สัมพันธ์กับความถูกต้องจริง **ใช้ผลรันซ้ำ 3 ครั้งแทน** ถ้าสามครั้งให้คนละระดับ นั่นคือความไม่แน่นอนที่วัดได้จริง
- 4. ต้องเป็น vision-language model งาน UX/UI ตัดสินจากภาพ การส่งเฉพาะโครงสร้าง JSON ของ Figma ไปให้ LLM ข้อความล้วนคือการตัดข้อมูลที่สำคัญที่สุดออก

1.4 ความเสี่ยงทางเทคนิคสองข้อที่ต้อง spike ก่อนล็อกสถาปัตยกรรม

#	คำถาม	ถ้าคำตอบเป็น “ไม่”
S1	Figma API คินพิคัดที่ปักหมุดบนภาพได้จริงไหม	พีเจอร์ “กดที่หลักฐานแล้วกระโดดไปที่ frame” ตายทั้งพีเจอร์ → คุณค่าหลักของหน้าจอตระหงหายไป → ต้องออกแบบวิธีชี้หลักฐานใหม่ทั้งหมด
S2	vLLM รัน VLM ระดับ 27–32B แบบ 4-bit บน RTX 5090 (Blackwell) ได้จริงไหม	ต้องลดขนาดโมเดล หรือย้ายไปใช้ API ซึ่งชนกับข้อจำกัดงบประมาณ

S2 มีความเสี่ยงเฉพาะตัว: Blackwell เป็นสถาปัตยกรรมใหม่ CUDA / PyTorch / ไบบริารี serving ต้องเวอร์ชันใหม่พอ ห้ามสมมติว่ารันได้ ทั้งสอง spike ต้องทำก่อนเขียนโค้ดจริง ดู เอกสารฉบับที่ 4 S2

2. จะรู้ได้อย่างไรว่าระบบดีพอ

2.1 กฎข้อเดียวที่ละเมิดไม่ได้

ข้อมูลที่ใช้วัดระบบ ห้ามใช้ปรับปรุงระบบ

ละเมิดข้อนี้แล้ว ตัวเลขทุกตัวในวิทยานิพนธ์ใช้ไม่ได้ และไม่มีทางรู้ว่าสูงเกินจริงเท่าไร

การละเมิดเกิดขึ้นโดยไม่ตั้งใจได้ง่ายมาก เช่น รันการจำลองผลของข้อเสนอแก้ rubric บนชุด test แล้วรับเฉพาะข้อที่ทำให้ดีขึ้น — นั่นคือการปรับปรุงบนชุด test เรียบร้อยแล้ว แม้จะไม่ได้ตั้งใจ

กลไกป้องกันที่ต้องมีในระบบ ไม่ใช่แค่ในวินัยของคน

- DatasetMembership** เป็นตารางสมาชิกที่ตรงไว้ ไม่ใช่การสุ่มตอน query — ถ้าสุ่มตอน query คำว่า “เปิดครั้งเดียว” ไม่มีความหมาย
- SystemMeta.last_test_access** และแถบ  บนทุกหน้าของแดชบอร์ด
- ระบบปฏิเสธและบันทึกทุกครั้งที่มีการพยายามอ่านชุด test

2.2 การแบ่งข้อมูลสามชุด

ชุด	ขนาด	ใช้ทำอะไร
dev	ส่วนใหญ่	ปรับ prompt · เลือก anchor · ทดลองทุกอย่าง · เปิดดูได้ไม่จำกัด
validation	~24 ขึ้น ก็นับจาก dev	จำลองผลของข้อเสนอแก้ rubric ก่อนตัดสินใจรับ
test	30–40 ขึ้น แชนจ์	เปิดครั้งเดียว 31 มี.ค. 2570

2.3 ตัววัดที่ใช้ และตัวที่ไม่ใช้

ตัววัด	ใช้ไหม	เหตุผล
Exact / adjacent agreement	✅ ตัวหลักในการรายงาน	CI แคบกว่า QWK ที่ N เดียวกัน · สื่อสารกับอาจารย์ได้ตรงที่สุด
QWK	✅ แต่ต้องมาพร้อม CI เสมอ	ปรับ chance แล้ว และให้น้ำหนักความห่างแบบกำลังสอง ซึ่งตรงกับความจริงว่าผิดไป 3 ระดับแย่กว่าผิดไป 1 ระดับมากกว่าสามเท่า
Mean signed error (bias)	✅ บังคับเก็บ	บอกทิศ ซึ่งเป็นข้อมูลชั้นเดียวที่บอกว่าจะแก้อย่างไร
MAE	⚠️ ใช้ประกอบ	ทั้งเครื่องหมาย ซึ่งเป็นข้อมูลที่น่าไปทำอะไรต่อได้ · ใช้ MAE อย่างเดียวคือการเห็นว่ามีปัญหาแต่ไม่รู้ว่ามีปัญหาไปทางไหน
ICC(2,1)	✅ สำหรับพหุคูณมนุษย์	เทียบกับวรรณกรรม portfolio assessment ได้
ค่าความมั่นใจที่ LLM รายงาน	❌	ไม่สัมพันธ์กับความถูกต้องจริง

หน่วยวิเคราะห์คือ (งาน × เกณฑ์) ไม่ใช่ชิ้นงาน — งาน 40 ชิ้น × 7 เกณฑ์ = 280 การตัดสินใจ ทำให้วัด bias รายเกณฑ์ได้

แต่ต้องยอมรับว่าคะแนนภายในงานเดียวกันสัมพันธ์กัน → effective $N < 280$ ทุก CI ต้องคำนวณด้วย cluster bootstrap ที่ resample ที่ระดับงาน/นักศึกษา ไม่ใช่ระดับเซลล์ มิฉะนั้น CI จะแคบเกินจริงและข้อสรุปทั้งหมดจะแข็งเกินความเป็นจริง

2.4 ตาราง “มี N เท่านี้ อ้างอะไรได้”

ตารางนี้ควรอยู่ในบทที่ 3 ของเล่ม เพราะมันคือคำสัญญาที่ประกาศล่วงหน้าว่าจะไม่อ้างเกินข้อมูล

N (ชิ้นงานที่อาจารย์ตรวจจริง)	วัดได้จริง	ปรับได้จริง	ห้ามอ้าง
10–30	ทิศของ bias รายเกณฑ์แบบหยาบ · รายการความผิดพลาดเชิงคุณภาพ · ความกำกวมของถ้อยคำ rubric	แก้ถ้อยคำที่ AI ตีความผิดชัด ๆ · เลือก anchor · แก่ระดับที่ AI ไม่เคยใช้เลย	QWK ทุกชนิด (CI ± 0.25) · การเทียบ prompt สองแบบด้วยตัวเลข
30–60	bias รายเกณฑ์ถ้า ≥ 0.25 ระดับ · exact/adjacent $\pm 13pp$ · MAE ± 0.16	การชดเชย bias เชิงเส้นรายเกณฑ์ · ปรับ threshold การส่งต่อให้คนทวน	QWK เป็นตัวเลขเดียว · เลือก prompt ที่ดีที่สุดจาก 5 ตัวด้วย QWK
60–120	QWK พร้อม CI กว้าง ~ 0.23 – $0.27 \rightarrow$ พุดได้แค่เป็น “ช่วง” · bias ที่เล็กถึง 0.20 ระดับ	prompt optimization แบบมีระเบียบ · isotonic/linear calibration	ว่าผ่านเกณฑ์ 0.70 · ว่า prompt ใหม่ดีกว่าเก่าเมื่อ $\Delta QWK < 0.10$
150–300	QWK CI ~ 0.16 – 0.19 · ตรวจจับ $\Delta QWK \geq 0.15$ แบบ paired ได้ที่ power ~ 0.9	ทุกอย่างข้างต้น + เลือกระหว่างสถาปัตยกรรมการตรวจที่ต่างกันจริง	ว่า $\Delta QWK 0.05$ มีความหมาย

สิ่งที่ตารางนี้บอกทันที: ที่ $n = 28$ ต่อเกณฑ์ (ตัวเลขของต้นแบบ) การเรียงอันดับ 7 เกณฑ์แล้วไล่แก้จากล่างขึ้นบนคือการไล่ตามสัญญาณรบกวน เพราะ CI รว ± 0.18 ทำให้เกณฑ์ที่ QWK 0.71 กับ 0.64 แยกจากกันไม่ได้

2.5 เพดานมนุษย์ — ตัวหารของทั้งวิทยานิพนธ์

วรรณกรรมบอกอะไร

Jonsson & Svingby (2007) review งานวิจัย 75 ชิ้นเรื่อง rubric ใน performance assessment:

- งาน open-ended ที่ประเมินสมรรถนะซับซ้อน (งานออกแบบ UX คือกรณีนี้เป๊ะ) มี exact rater consensus เพียง 55–75% แม้ใช้ rubric
- เกณฑ์ที่ถือว่าเชื่อถือได้: exact $\geq 70\%$ · adjacent $\geq 90\%$
- anchor / benchmark example ช่วยเพิ่ม agreement ได้มากที่สุด มากกว่าการอบรมผู้ตรวจ
- rubric เฉพาะเจาะจงกับโจทย์ให้ผลดีกว่า generic rubric
- สเกลที่มีระดับน้อยกว่าให้ consensus สูงกว่า

Portfolio assessment ในหลักสูตรแพทย์ (Ewha Womans University): ICC ของผู้ตรวจทุกคน 0.382 · หลังคัดผู้ตรวจที่แย่ออกขึ้นเป็น 0.442 · สหสัมพันธ์รายคนกับ gold standard กระจายตั้งแต่ 0.42 ถึง 0.89

แต่เมื่อผู้ตรวจได้รับการอบรมและมีเกณฑ์ที่ระบุชุด ICC ขึ้นถึง ≥ 0.81 ได้ → ปัญหาไม่ได้อยู่ที่มนุษย์ แต่อยู่ที่ว่า rubric ชัดพอ และมี anchor หรือเปล่า

แปลว่าอะไรกับโครงการนี้

1. ถ้าอาจารย์สองคนตรงกัน exact เพียง ~65% การไล่ให้ AI ทำได้ 90% คือการ fit สัญญาณรบกวน ไม่ใช่ความแม่นยำ
2. ต้องวัด human-human ก่อนวัด AI — ให้อาจารย์ (หรืออาจารย์ + ผู้ช่วยสอน) ตรวจงานชุดเดียวกัน 20–30 ชิ้น
3. ถ้าหาผู้ตรวจคนที่สองไม่ได้ ใช้ intra-rater reliability แทน: อาจารย์คนเดิมตรวจงานชุดเดิมซ้ำหลังผ่านไป 2–3 สัปดาห์ โดยสุ่มลำดับใหม่ — เป็นเพดานที่อ้างอิงได้จริงและทำได้ด้วยคนเดียว
4. เป้าหมายที่ป้องกันตัวได้ในห้องสอบ

“AI-teacher agreement ไม่ต่ำกว่า teacher-teacher (หรือ teacher-self) agreement เกิน 0.10 QWK” ไม่ใช่ “QWK ≥ 0.70 ” ลอย ๆ

ข้อ 4 คือความแตกต่างระหว่างวิทยานิพนธ์ที่ตอบคำถามกรรมการได้กับที่ตอบไม่ได้ “QWK 0.68” ตอบไม่ได้ว่าดีหรือแย่ แต่ “0.68 [0.58, 0.79]” เทียบกับเพดานมนุษย์ 0.71 [0.60, 0.81]” ตอบได้ทันที

เกณฑ์ความสำเร็จที่ประกาศล่วงหน้า

ขอบล่างของ 95% CI ของ QWK $\geq 0.60 \cdot |\text{bias}|$ ทุกเกณฑ์ < 0.25 ระดับ · adjacent agreement $\geq 90\%$

ตั้งเป้าที่ CI ไม่ใช่ point estimate — บรรลุได้จริงที่ $N \sim 150$ และป้องกันตัวได้ในห้องสอบ

2.6 หัววิธีที่ทำให้ N น้อยมีพลังมากขึ้น

1. หน่วยวิเคราะห์เป็น (งาน × เกณฑ์) พร้อม cluster bootstrap
2. วัดผลต่างแบบ paired เสมอ — เทียบ prompt เก่า/ใหม่บนงานชุดเดียวกัน แล้ว bootstrap ที่ผลต่าง ตัดความแปรปรวนจาก “งานชุดนี้ยากหรือง่าย” ออกไป
3. ตั้งเป้าที่ CI
4. รายงานเทียบเพดานมนุษย์เสมอ
5. ใช้ metric ที่ไม่ปรับ chance เป็นตัวหลัก (exact/adjacent, MAE) เพราะ CI แคบกว่า

2.7 เมื่อ rubric เปลี่ยนเวอร์ชัน

RubricVersion ใหม่ = ไม่บรรทัดใหม่ คะแนนจากคนละเวอร์ชันเทียบกันตรง ๆ ไม่ได้

ทางแก้: bridge set 15–25 ชั้นที่ตรวจด้วยทั้งสองเวอร์ชัน ถ้าไม่มี bridge set กราฟแนวนอนต้องแสดงเป็นเส้นประ เพื่อสื่อสารด้วยรูปว่าช่วงนั้นเทียบกันไม่ได้ แทนที่จะลากเส้นทับต่อกันแล้วให้คนเข้าใจผิด

ราคาของ bridge set หนึ่งชุด $\approx$ 2.5 ชั่วโมงของอาจารย์ — ต้องแสดงราคานี้บนหน้าจอตอนกดรับข้อเสนอ ไม่ใช่ให้รู้ทีหลัง

2.8 ลำดับการใช้เวลาตรวจของอาจารย์

เวลาของอาจารย์คือทรัพยากรที่หายากที่สุดในโครงการนี้ ลำดับที่ให้ผลตอบแทนสูงสุด:

1. ตรวจซ้ำเพื่อวัดเพดานมนุษย์ (20–30 ชั้น) — ถูกที่สุด ให้ผลตอบแทนทางวิชาการสูงสุด และต้องทำก่อนสิ่งอื่นทั้งหมด
2. ตรวจแบบ blind เพื่อสร้าง gold set — เป็นเชื้อเพลิงของทุกอย่างที่เหลือ
3. เลือก anchor example — ผลตอบแทนต่อชิ้นสูงมาก
4. ตรวจเพิ่มเพื่อขยายเส้นโค้งการเรียนรู้

3. การได้มาซึ่งข้อมูล — และเหตุผลที่หนักที่แข็งที่สุดคือวันเปิดภาค

3.1 วิชาที่เปิดสอนทุกภาค ซึ่งเปลี่ยนแผนทั้งหมด

ภาค 1/2569 มีนักศึกษาจริง มีงานจริง และอาจารย์ต้องตรวจอยู่แล้ว

ถ้าเปลี่ยนวิธีบันทึกจาก “คะแนนรวม” เป็น “คะแนนรายเกณฑ์ + เวลาที่ใช้ต่อชิ้น” จะได้ gold set มาแทบฟรี และข้อมูลชุดนี้ ไม่ถูก anchor โดยธรรมชาติ เพราะตอนนั้นยังไม่มี AI ให้เห็น

	ทาง A — ตรวจงานเก่าย้อนหลัง	ทาง B — บันทึกจากงานสด
ต้นทุนเวลาอาจารย์	+20–25 ชม.	~0 (ตรวจอยู่แล้ว)
ลิงก์ Figma เน่า	เป็นปัญหาใหญ่	ไม่มีปัญหา
ตรวจด้วย rubric ใหม่	ต้องตรวจใหม่ทั้งหมด	ใช้ rubric ใหม่ตั้งแต่ต้น
ถูก anchor ใหม่	ต้องออกแบบ blind ให้ดี	ไม่ถูกโดยโครงสร้าง
สถานะ	ของเสริม	ทางหลัก

3.2 ผลที่ตามมา: หนักที่แข็งที่สุดของโครงการคือวันเปิดภาค 1/2569

ทุกสัปดาห์ที่ผ่านมาโดยไม่บันทึกรายเกณฑ์ คือข้อมูลที่หายถาวร — เก็บย้อนหลังไม่ได้เลย

ของสองอย่างที่ต้อเสร็จก่อนเปิดภาค 1 และไม่ใช้ซอฟต์แวร์

#	สิ่งที่ต้องมี	เวลาที่ใช้
1	rubric ที่อาจารย์ยืนยันแล้ว	1–2 ชั่วโมง
2	สเปรดชีตบันทึกคะแนนรายเกณฑ์ + ช่อง จับเวลาต่อชิ้น	~1 วัน

ข้อผูกมัดที่ต้องเข้าใจ: rubric ที่ยืนยันก่อนเปิดภาค 1 ควรถือว่าล็อกไปตลอดโครงการ เพราะถ้าเปลี่ยนกลางทาง ข้อมูลของภาค 1 กับภาค 2 เทียบกันไม่ได้ เว้นแต่จะยอมทำ bridge set

นี่คือเหตุผลที่ deliverable ชิ้นแรกของโครงการทั้งโครงการคือสเปรดชีต ไม่ใช่ซอฟต์แวร์

3.3 ข้อมูลที่จะได้จริง

	จำนวน
ชิ้นงานที่อาจารย์ตรวจ blind ต่อภาค	100–150
คู่คะแนนระดับเกณฑ์ต่อภาค	~330–1,000
นักศึกษา/กลุ่มที่เป็นคลัสเตอร์อิสระ	40–60 ← นี่คือ N จริงของงานวิจัย
รวมสองภาค	~660–2,000 คู่ · 80–120 คลัสเตอร์

ย่อหน้านี้ต้องอยู่ในบทที่ 3 ตรง ๆ: ตัวเลข 2,000 ดูเหมือนพอสำหรับ DPO แต่ **effective N คือหลักสิบ** การรายงานว่ามีข้อมูล 2,000 ตัวอย่าง” โดยไม่พูดถึงคลัสเตอร์คือการรายงานที่ทำให้เข้าใจผิด และเป็นจุดที่กรรมการจับได้

3.4 การซ่อมใหญ่ปลายภาค 1

ปลายภาค 1 (พ.ย.–ธ.ค. 2569) เอา 1–2 ชิ้นงานมาเดินระบบจริง

เหตุผล: ภาคทดลอง (ภาค 2/2569) เป็นภาคเดียวกับภาคที่ต้องสอบจบ ถ้าเปิดใช้จริงครั้งแรกแล้วพัง จะไม่มีภาคที่สองให้แก้ตัว การซ่อมใหญ่คือทางเดียวที่ทำให้ความเสี่ยงนี้ไม่ใช่ความเสี่ยงที่ไม่มีการป้องกันเลย

ข้อจำกัดที่ต้องรู้ตอนเขียน มคอ.3 ของภาค 2: ภาคทดลองคือภาคที่ต้องสอบจบ → มีเฉพาะงานที่ตรวจก่อน 31 มี.ค. 2570 เท่านั้นที่เข้าเล่มได้ → ควรวางแผนงาน Figma ที่สำคัญไว้ครั้งแรกของภาค 2

4. RL — สิ่งทีโ้ทย์เรียกว่า RL คืออะไรได้จริง

4.1 พูดตรง ๆ ก่อน: สิ่งทีคนเรียกว่า RL ส่วนใหญ่ในบริบทนี้ไม่ใช่ RL

สาย	ทำอะไร	ตะะ weight ใหม่	เรียกว่า RL ได้ไหม
สาย P — prompt optimization	ใช้ GEPA/OPRO คั่นถ้อยคำของคำอธิบาย + เลือกชุด anchor อัตโนมัต์ โดยมี agreement บน dev เป็น objective	ไม่	ไม่ใช่ — วรรณกรรมเรียก self-refine / reflective prompt search
สาย D — preference learning	DPO/ORPO บนโมเดลเปิดด้วย LoRA จากคู่ (คำตัดสินที่อาจารย์ยอมรับ vs ที่อาจารย์แก้)	ใช่ (LoRA)	กึ่ง — พัฒนามาจาก RLHF แต่ไม่มี reward model และไม่มี rollout
สาย B — contextual bandit	เลือก “กลยุทธ์การตรวจ” ต่อชิ้นงาน แล้วเรียนรู้จากผลย้อนกลับ	ไม่	ใช่ — RL ตัวจริงตัวเดียวในโครงการ

การเขียนผิดตรงนี้คือจุดที่กรรมการจับได้ง่ายที่สุด ในเล่มต้องเขียนว่าสาย D เป็น preference optimization และอธิบายว่าต่างจาก RLHF เต็มรูปตรงที่ไม่มี reward model และไม่มีการ sample จากนโยบายระหว่างเทรน

สาย B ราคาถูกที่สุด (ไม่ต้อง GPU ไม่ต้องเทรน ใช้ ~30 observation ต่อ arm) และเป็นตัวเดียวที่ทำให้เล่มพูดคำว่า RL ได้โดยไม่ผิตินยาม จึงวางเป็นฐานที่ต้อมี

4.2 คำถามวิจัย — หนึ่งประโยค

ทีระดับข้อมูลของรายวิชาเดียว (นักศึกษา 40–60 คน 2 ภาคการศึกษา) การปรับ prompt อัตโนมัต์ กับการเรียนรู้จากความชอบของอาจารย์ ทำให้ agreement ระหว่าง AI กับอาจารย์เพิ่มขึ้นเป็นเส้นโค้งอย่างไรเมื่อจำนวนชิ้นงานที่อาจารย์ตรวจเพิ่มขึ้น และต้อใช้กี่ชิ้นจึงจะแยกสองวิธีออกจากกันได้อย่างมีนัยสำคัญ

คำถามย่อยสามข้อ

- RQ1 (เส้นโค้ง): agreement เพิ่มเท่าไรต่อชิ้นงานที่อาจารย์ตรวจ และเริ่มแบนที่ N เท่าไร
- RQ2 (เปรียบเทียบ): ที่ N เท่ากัน สายไหนดีกว่า และจุดสลับอันดับ (ถ้ามี) อยู่ที่ N เท่าไร
- RQ3 (นัยเชิงปฏิบัติ): ถ้าอาจารย์มีเวลาตรวจได้ X ชิ้นต่อเทอม ควรลงแรงไปทางไหน

4.3 ทำไมกรอบนี้ล้มไม่ได้โดยโครงสร้าง

เส้นโค้งการเรียนรู้เป็นผลการทดลองไม่ว่าจะชันหรือแบน

- ชัน = เรียนรู้ได้จริง พร้อมตัวเลขว่าต้องใช้ข้อมูลเท่าไร
- แบน = ข้อมูลระดับนี้ไม่พอ พร้อมหลักฐานเชิงปริมาณและการประมาณว่าต้องมีเท่าไรจึงจะพอ ซึ่งเป็นคำตอบที่มีค่าต่อทุกคนที่คิดจะทำระบบแบบเดียวกันในวิชาเดียว

เทียบกับการตั้งคำถามว่า “RL ทำให้ดีขึ้นไหม” ซึ่งถ้าผลออกมาว่าไม่ ก็เหลือแค่ “ไม่พบความแตกต่าง” — อ่อนกว่ามากในห้อยสอบ

4.4 สมมติฐานที่ประกาศล่วงหน้า

เขียนลงเล่มก่อนเริ่มเก็บข้อมูล เพื่อไม่ให้เป็นการอธิบายผลย้อนหลัง

#	สมมติฐาน	ฐานที่มา
H1	ทั้งสองสายให้เส้นโค้งที่ชันมากช่วง N = 0-60 แล้วแบนเร็ว	ที่ N หลักสิบ bias รายเกณฑ์คือสิ่งที่แก้ได้ คุ่มที่สุดและแก้ได้เร็ว
H2	สายปรับ prompt ขณะที่ทุกค่า N ในช่วงที่โครงการนี้เื้อมถึง	GEPA ชนะ GRPO เฉลี่ย 6% / สูงสุด 20% ด้วย rollout น้อยกว่า 35 เท่า
H3	ผลต่างระหว่างสองสาย มี CI คร่อมศูนย์ตลอด ที่ $N \leq 200$	paired Δ QWK ต้องการ N ~150-300 จึงตรวจจับผลต่าง 0.15 ได้ที่ power 0.9 และผลต่างที่คาดในที่นี้เล็กกว่านั้น
H4	ตัวที่ขยับ agreement ได้มากที่สุดต่อหน่วยแรง ไม่ใช่ทั้งสองสาย แต่คือ anchor example + การชดเชย offset รายเกณฑ์	วรรณกรรม rubric calibration

ถ้า H3 เป็นจริงตามคาด นั่นคือผลของโครงการ ไม่ใช่ความล้มเหลวของโครงการ — และนี่คือเหตุผลทั้งหมดที่ต้องเขียน H3 ไว้ล่วงหน้า

4.5 วิธีสร้างเส้นโค้งการเรียนรู้

แกน x = จำนวนชิ้นงานที่อาจารย์ตรวจแบบ blind ไม่ใช่จำนวนแถวคะแนน — เพราะนี่คือต้นทุนจริงที่อาจารย์จ่าย และเป็นคำตอบที่เอาไปใช้ได้จริง

จุดบนแกน x: $N \in \{20, 40, 60, 80, 100\}$ ในภาค 1 $\rightarrow$ ต่อถึง $\{150, 200, 250\}$ เมื่อรวมภาค 2

ขั้นตอน

1. สุ่มชุดย่อยแบบซ้อนกัน (nested) — ชุด $N=20$ ต้องเป็นสับเซตของ $N=40$ เสมอ เพื่อให้เส้นโค้งสะท้อน “ข้อมูลเพิ่มขึ้น” ไม่ใช่ “บังเอิญได้ชุดที่ง่ายกว่า”
2. สุ่มซ้ำ 3 ชุดต่อหนึ่งค่า N แล้วรายงานค่าเฉลี่ย $\pm$ ช่วง — ถ้าไม่ทำซ้ำ เส้นโค้งจะขึ้น ๆ ลง ๆ จากเสียงรบกวนล้วน ๆ และตีความไม่ได้เลย
3. สุ่มที่ระดับนักศึกษา/กลุ่ม (GroupKFold) ไม่ใช่ระดับแถว
4. ทุกจุดวัดผลบน test set ชุดเดียวกันที่แช่แข็งไว้ · ระหว่างทางใช้ dev เท่านั้น
5. รวม 3 seed $\times$ 4 ค่า $N \times 2$ สาย = 24 รอบ — ถ้าเห็นว่าเยอะเกิน ให้ตัดค่า N ที่ ไม่ใช้ตัดจำนวน seed
6. CI ด้วย cluster bootstrap ที่ระดับนักศึกษา · การเทียบ P กับ D ต้อง paired บนงานชุดเดียวกัน แล้ว bootstrap ที่ผลต่าง

กับดักที่ต้องเขียนกันไว้ในเล่ม: ถ้าเส้นโค้งขึ้นแล้วลงแล้วขึ้น อย่ารีบตีความว่า “โมเดลเรียนรู้แล้วลิม” — ที่ N ระดับนี้ ความกว้างขนาดนั้นอธิบายได้ด้วยเสียงรบกวนอย่างเดียว การทำ 3 seed ต่อจุดมีไว้เพื่อให้เห็นข้อนี้ด้วยตาตัวเอง ไม่ใช่เพื่อความสวยของกราฟ

หมายเหตุเรื่อง baseline: สาย D ต้องเทียบกับ สาย P ที่ optimize แล้ว ไม่ใช่เทียบกับ prompt ดิบ — ไม่งั้นเครดิตของการปรับ prompt จะถูกนับเป็นผลงานของ preference learning

4.6 การสร้างคู่ preference — จุดที่ทำให้ฝึกกันบ่อยที่สุด

วิธีที่ดูตรงไปตรงมาแต่ผิด: เอาคำตัดสินของอาจารย์เป็นตัวชนะ และคำตัดสินของ AI เป็นตัวแพ้

ทำไมผิด: ข้อความของอาจารย์อยู่นอกการกระจายของโมเดล DPO จะไล่ตามสไตล์การเขียนแทนที่จะไล่ตามการตัดสิน

วิธีที่ถูก (best-of-n distillation)

- 1. ให้โมเดลสร้างคำตัดสินเอง $k = 4$ แบบ ต่อหนึ่ง (ชิ้นงาน $\times$ เกณฑ์)
- 2. ตัวชนะ = ตัวที่ระดับตรงกับอาจารย์ที่สุด · ตัวแพ้ = ตัวที่ห่างที่สุด
- 3. ถ้า k ตัวให้ระดับเดียวกันหมด ทั้งคู่ — ไม่มีสัญญาณให้เรียน
- 4. ใช้เฉพาะคู่จากงานที่ตรวจแบบ blind เท่านั้น

4.7 นิยาม state / action / reward ของสาย B

องค์ประกอบ	นิยามในโครงงานนี้
context (state)	ประเภทชิ้นงาน · เกณฑ์ที่กำลังตรวจ · rubric_version_id · สัญญาณจากชั้นกฎ (จำนวนเฟรม จำนวน component ผลตรวจ contrast) · ความซับซ้อนของไฟล์
action (arm)	กลยุทธ์การตรวจ 5 ตัว: (1) zero-shot · (2) few-shot 3 anchor · (3) best-of-3 แล้ว majority · (4) ให้บรรยายก่อนให้คะแนน · (5) โมเดลเล็กแทนโมเดลใหญ่
reward	$1 - \frac{ \text{ระดับที่ AI ให้} - \text{ระดับที่อาจารย์ให้} }{(\text{จำนวนระดับ} - 1)} \in [0,1]$ · มาช้า (รู้ผลตอนอาจารย์ตรวจเสร็จ) · วัดได้เฉพาะบนชิ้นที่ blind
policy	Thompson sampling หรือ LinUCB
ที่ยากกว่าตำรา	reward ไม่นิ่ง — เมื่อ rubric หรือ JudgePromptVersion เปลี่ยน ค่าที่เรียนมาก็เก่าทันที ต้องใช้ bandit แบบ sliding window หรือ discount และใส่ rubric_version เป็นส่วนหนึ่งของ context

ต้นทุนของแต่ละ arm ต่างกัน (best-of-3 แพงกว่า zero-shot 3 เท่า) จึงควรใช้ reward สุทธิ = ความแม่นยำ - $\lambda \times$ ต้นทุน และรายงานทั้งแบบคิดและไม่คิดต้นทุน — ทำให้ผลการทดลองมีคำตอบเชิงปฏิบัติที่ใช้ได้ทันที

4.8 Reward hacking สี่แบบและวิธีตรวจจับ

#	รูปแบบ	ทำไมเกิด	วิธีตรวจจับ
RH1	ให้ระดับกลางทุกครั้ง	MAE ต่ำที่สุดถ้าการกระจายระจุกกลาง	ดูการกระจายของระดับที่ออกเทียบกับของอาจารย์ · QWK จะพังทันทีแม้ MAE ดูดี
RH2	เตาจากการกระจายของชั้น ไม่ได้ดูงาน	ถ้ารู้ว่าชั้นนี้ส่วนใหญ่ได้ระดับ 3 การเตา 3 ก็ได้ reward สูง	swap test — ป้อนไฟล์ของนักศึกษาคนอื่นเข้าไปโดยคงบริบทอื่นไว้ ถ้าคะแนนแทบไม่เปลี่ยน แปลว่าไม่ได้ดูงานจริง
RH3	เขียนเหตุผลยาวและน่าเชื่อถือจนอาจารย์ไม่แก้	ถ้า reward วัดจาก “อาจารย์ไม่แก้” ก็จงใจให้ทำให้อาจารย์เชื่อ ไม่ใช่ให้ตัดสินถูก	นี่คือเหตุผลที่ reward ต้องนับเฉพาะชั้นที่ blind — ถ้าอาจารย์ไม่เห็นคะแนนและเหตุผลของ AI ตอนตรวจ ช่องทางนี้ปิดสนิท
RH4	จูนไปที่ตัววัดจากการเปิด test ซ้ำ	ทำโดยไม่รู้ตัวได้ง่ายมาก	DatasetMembership ที่ตรงไว้ + ระบบปฏิเสธและบันทึกทุกครั้งที่ยพยายามอ่าน test

swap test ควรเป็นการทดลองย่อยในเล่ม ไม่ใช่แค่ขั้นตอนตรวจสอบภายใน — มันตอบคำถามที่กรรมการถามแน่ ๆ ว่า “รู้ได้อย่างไรว่า AI ดูงานจริง ไม่ได้เตา” ด้วยตัวเลข ทำได้ถูกมาก (รันซ้ำ 20–30 ชั้น) และให้ผลที่มีความหมายไม่ว่าออกมาทางไหน

4.9 ทรัพยากรและเวลาเครื่อง

การมี GPU ของภาคเปลี่ยนแผนในทางที่ดีขึ้นชัดเจน — เดิมวางไว้บน Kaggle (T4 16GB จำกัด 30 ชม./สัปดาห์) และแก้ปัญหา PDPA ไปในตัว เพราะงานนักศึกษาไม่ต้องออกนอกคณะ

แต่ต้องระวังสองข้อ

- GPU ไม่ได้แก้ค่า API ของโมเดล frontier — baseline และการตรวจจริงประจำวันยังเรียก API ภายนอก งานที่ทำซ้ำทุกสัปดาห์และงานที่รันซ้ำเยอะต้องอยู่บนโมเดลเปิด ส่วน API เก็บไว้เป็นจุดอ้างอิงระดับบนสุดที่รันไม่บ่อย

2. ต้องมีตัวนับต้นทุนต่อ call และเพดานงบที่หยุดเรียก API เองเมื่อชน

VRAM ต่อการ์ด	ทำอะไรได้
16 GB	QLoRA 7–8B ได้ · 13B ไม่ไหว
24 GB	QLoRA 13B สบาย · LoRA 7–8B ไม่ quantize ได้ — จุดที่คุ้มที่สุด
32 GB (RTX 5090)	VLM 27–32B แบบ 4-bit สำหรับ inference — ต้อง spike ยืนยัน
40–80 GB	30B+ · full fine-tune 7B

ประมาณการเวลาเครื่อง: QLoRA 7–8B $\approx$ 1–3 ชม./รอบ $\times$ 24 รอบ $\approx$ 25–70 ชั่วโมง กระจายตลอดภาค 2 ได้

4.10 การเชื่อมกับระบบจริง

แยกออกจากระบบ ไม่ต่อเข้า MVP — สาย P และ D อยู่ในรูปสคริปต์วิจัยที่อ่านข้อมูลแบบอ่านอย่างเดียว ไม่มีสิทธิ์เขียนกลับ

ผลของ	นำกลับเข้าระบบได้ไหม
สาย P	ได้และควรนำกลับ — ออกมาเป็น JudgePromptVersion ใหม่ที่ต้องผ่านประตูอนุมัติ เหมือนข้อเสนออื่น ไม่มีสิทธิ์พิเศษ
สาย D (LoRA adapter)	ไม่นำกลับใน MVP — จะเปลี่ยนสถาปัตยกรรมจาก “เรียก API” เป็น “โฮสต์โมเดลเอง” ซึ่งเป็นการตัดสินใจระดับสถาปัตยกรรม ไม่ใช่ผลพลอยได้ของการทดลอง
สาย B (bandit)	ได้ในทอมถัดไป — เป็นตารางเลือกกลยุทธ์ต่อ context ซึ่งฝังเป็นค่าคงที่ได้โดยไม่ต้องมี bandit ทำงานจริงในระบบ

เหตุผลของการแยก: ถ้าการทดลองต่ออยู่กับระบบที่นักศึกษาใช้จริง เวลาการทดลองพัง คะแนนของนักศึกษาก็พังด้วย และจะไม่มีใครกล้าทดลองอะไรอีกเลยตลอดโครงการ

5. ปฏิทินและจุดตัดสินใจหยุด

สอบจบปลายภาค 2/2569 (ราว เม.ย.-พ.ค. 2570) · วันที่ด้านล่างคือวันตัดสินใจจริง ไม่ใช่วันประมาณ

วันที่	ประตุ	ถ้าไม่ผ่าน
31 ต.ค. 2569	P0 เสร็จ — ระบบบันทึกครบ · blind ตั้งแต่ขึ้นงานแรก · ตรวจซ้ำรอบ 0 เสร็จ มี เพดานมนุษย์เป็นตัวเลขแล้ว	หยุดสาย RL ทั้งหมดทันที พุ่มเวลาที่เหลือ ให้ระบบหลัก — ไม่มีเพดานมนุษย์ = ไม่มี ตัวหาร = ทุกตัวเลขหลังจากนี้ตีความไม่ได้
31 ธ.ค. 2569 (จบภาค 1)	คู่คะแนน blind ≥ 300 คู่ จากนักศึกษา ≥ 35 คลัสเตอร์ · สาย P รันครบอย่างน้อย 2 จุดบนเส้นโค้ง	ตัดสาย D ทั้ง เดินต่อด้วยสาย P + bandit รายงานเป็นข้อจำกัดด้านข้อมูล
28 ก.พ. 2570	จุดตัดสินใจหลัก — สาย D ต้องรันจบ end-to-end บนข้อมูลจริงอย่างน้อย 1 รอบ (ไม่ต้องชนะ แค่ต้องรันจบและมี ตัวเลข)	หยุดสาย D เขียนเป็นผลเชิงลบตาม S6 — ห้ามต่อเวลา
31 มี.ค. 2570	แข่งแข่งการทดลอง — ไม่รันอะไรใหม่อีก เปิด test set ครั้งเดียว คำนวณผล ทั้งหมด	ไม่มีทางเลือกอื่น วันนี้ตายตัว
เม.ย.-พ.ค. 2570	เขียนเล่ม + สอบ	

กฎเหล็กสองข้อ

- ห้ามเลื่อนวันที่ 28 ก.พ. ไม่ว่าผลจะ “ใกล้จะได้แล้ว” แค่ไหน — นี่คือการดักที่กลืนโครงการบ้อยที่สุด และ “ใกล้จะได้แล้ว” เป็นความรู้สึกที่เกิดได้ตลอดเวลาโดยไม่สัมพันธ์กับความจริง
- 31 มี.ค. คือวันเปิด test set ครั้งเดียว ถ้าเปิดแล้วผลไม่ถูกใจ ห้ามกลับไปแก้แล้วเปิดใหม่ ถ้าทำ ตัวเลขในเล่มจะไม่ใช้ผล การทดลองอีกต่อไป และต้องเขียนกำกับว่าเปิดกี่ครั้ง

6. ย่อหน้าทางถอย — เขียนไว้ให้ใช้ได้ทันที

ใช้แทนหัวข้อ “ผลการทดลองส่วน RL” ได้เลยถ้าถึง 28 ก.พ. 2570 แล้วสาย D ไปไม่ถึงไหน — แก้แค่ตัวเลขในช่องว่าง

ผลการทดลองด้านการเรียนรู้จากความชอบของผู้สอน

การทดลองนี้ตั้งคำถามว่า ที่ระดับข้อมูลของรายวิชาเดียว การเรียนรู้จากความชอบของผู้สอนให้ผลต่างจากการปรับ prompt อัตโนมัติหรือไม่ และต้องใช้ชิ้นงานที่ผู้สอนตรวจก็ขึ้นจึงจะแยกสองวิธีออกจากกันได้

ผลปรากฏว่า ที่จำนวนข้อมูลสูงสุดที่เก็บได้จริงในสองภาคการศึกษา (___ คู่คะแนน จากนักศึกษา ___ คน) ช่วงความเชื่อมั่น 95% ของผลต่างระหว่างสองวิธียังครอบคลุม (Δ QWK = ___ [___, ___]) กล่าวคือข้อมูลระดับนี้ไม่เพียงพอที่จะสรุปว่าวิธีใดดีกว่า ผลนี้ตรงกับสมมติฐาน H3 ที่ประกาศไว้ล่วงหน้าก่อนเริ่มเก็บข้อมูล และสอดคล้องกับการทบทวนวรรณกรรมที่พบว่างานที่ใช้ preference learning กับการให้คะแนนอัตโนมัติสำเร็จนั้นใช้ข้อมูลระดับหมิ่นขึ้น ซึ่งห่างจากข้อมูลของรายวิชาเดียวสองอันดับของขนาด

จากเส้นโค้งการเรียนรู้ที่วัดได้ ประเมินการว่าต้องมีคู่คะแนนอิสระประมาณ ___ คู่ จากนักศึกษาไม่น้อยกว่า ___ คน จึงจะตรวจจับผลต่างขนาด 0.15 QWK ได้ที่ power 0.8 ซึ่งเทียบเท่ากับการเก็บข้อมูลต่อเนื่อง ___ ภาคการศึกษา หรือการขยายไปยังรายวิชาอื่นในหลักสูตรพร้อมกัน ___ รายวิชา

ผลเชิงลบนี้มีนัยเชิงปฏิบัติที่ชัดเจน: สำหรับผู้สอนที่ต้องการนำ AI มาช่วยตรวจงานในรายวิชาเดียว การลงแรงไปที่การออกแบบตัวอย่างอ้างอิงและการชดเชยความเอนเอียงเชิงตัวเลขรายเกณฑ์ ให้ผลตอบแทนต่อหน่วยแรงสูงกว่าการฝึกโมเดลอย่างมีนัยสำคัญ ระบบที่พัฒนาขึ้นจึงออกแบบให้กลไกดังกล่าวเป็นส่วนหลัก และวางส่วนการฝึกโมเดลไว้เป็นส่วนขยายที่จะเปิดใช้เมื่อข้อมูลสะสมถึงระดับที่วิเคราะห์ไว้แล้วเท่านั้น

ทั้งนี้การทดลองส่วน contextual bandit ซึ่งเป็นการเรียนรู้แบบเสริมกำลังที่นิยาม state, action และ reward ได้ครบถ้วน สามารถดำเนินการได้จนจบและให้ผล ___

หมายเหตุถึงคนที่เขียนเล่ม: ย่อนหานี้แข็งแรงกว่าย่อหน้า “เราทำ RL แล้วดีขึ้น 3%” ที่ไม่มี CI มาก เพราะมันตอบคำถามที่มีคนอยากรู้จริง มีตัวเลขประกอบทุกข้ออ้าง และแสดงว่าผู้ทำเข้าใจข้อจำกัดของวิธีที่ตัวเองใช้ . งานที่รายงานผลเชิงลบอย่างมีระเบียบเป็นที่ยอมรับในวรรณกรรม

7. สิ่งที่ไม่ห้ามเขียนในเล่ม

ห้ามเขียน	เพราะ	เขียนแทนด้วย
“TABEE รองรับการให้หลักฐานที่ AI สร้าง”	ค้นหาคำว่าไม่พบคำว่า AI เลย — ไม่ใช่ทั้งอนุญาตและห้าม	“กรอบ TABEE ไม่ได้ระบุถึงหลักฐานที่สร้างโดย AI ไว้ ระบบจึงออกแบบให้ผู้สอนเป็นผู้ตัดสินใจเพื่อให้สอดคล้องกับข้อ 1.7 เรื่องการสืบย้อนผู้ตัดสิน”
“เกณฑ์การบรรจุ CLO ที่ 70/60 เป็นมาตรฐาน”	ไม่มีแหล่งปฐมภูมิของไทยรองรับ	“ใช้ 70/60 เป็นค่าตั้งต้นที่ผู้สอนแก้ได้ โดยยังรอเกณฑ์ที่มหาวิทยาลัยกำหนด”
“ระบบส่งออกแบบฟอร์ม มคอ.5”	มคอ.หมดสถานะข้อบังคับตั้งแต่ ก.ย. 2565 และ สจล. เลิกใช้ชื่อนี้แล้ว	“ระบบส่งออกข้อมูลที่น่าไปประกอบ Course Syllabus / Module Specification ได้”
“โครงการนี้ใช้ Reinforcement Learning ในการปรับปรุงการให้คะแนน” (ถ้าทำแค่สาย P)	ผิดนิยาม เป็นจุดที่กรรมการจับได้ง่ายที่สุด	“ใช้ reflective prompt optimization ร่วมกับ contextual bandit ซึ่งเป็น RL ที่นิยาม state/action/reward ได้ครบ”
“ระบบมีความแม่นยำ 94%”	ตัวเลข agreement ที่ไม่มีตัวหารไม่มีความหมาย	“adjacent agreement 94% เทียบกับเพดานมนุษย์ 96%”
“มีข้อมูล 2,000 ตัวอย่าง”	effective N คือหลักสิบ	“มีคู่คะแนน 2,000 คู่จากนักศึกษา 50 คน ซึ่งเป็นคลัสเตอร์อิสระ 50 หน่วย”